

ZMM MOVILIDAD PREDICTIVA

Documento de Contexto de Proyecto

Predicción de Colapso Vial en Parques Industriales · Zona Metropolitana de Monterrey

Versión 3 — Abril 2026 (Actualizado tras completar NB05 y NB06)

1. Metadatos del Proyecto

Campo	Valor
Proyecto	ZMM Movilidad Predictiva (zmm-movilidad-predictiva)
Autor principal	Cristopher — Estudiante FIME, 5.º semestre, Ing. en Tecnología de Software
Colaborador	Adrián — Responsable de conseguir y subir las bases de datos crudas
Contexto académico	Curso Samsung Innovation Campus + UDEM — Módulo ML con certificación CENEVAL
Fecha de entrega	10 de abril de 2026
Repositorio GitHub	github.com/ZeninKris/zmm-movilidad-predictiva (rama main)
Entorno de desarrollo	Google Colab + Google Drive (Proyecto_ZMM/data_raw y data_processed)
Stack principal	Python, pandas, numpy, geopandas, scikit-learn, folium, requests
Libro de referencia	Feature Engineering for Machine Learning — O'Reilly (Alice Zheng & Amanda Casari)
Versión del documento	v3 — Abril 2026 (actualizado tras completar NB05 y NB06)

2. Problema y Pregunta de Investigación

2.1 Pregunta central

¿Cuánto tiempo tardan realmente los trabajadores en llegar a los principales parques industriales de la ZMM, y qué zonas enfrentarán un colapso vial crítico en los próximos 3 años?

2.2 Causas estructurales

- Expansión periférica acelerada: crecimiento habitacional en Apodaca, García y Pesquería sin infraestructura proporcional.
- Desequilibrio espacial: concentración de empleo en parques industriales vs. zonas residenciales lejanas.

- Infraestructura rebasada: la mancha urbana supera la capacidad de las arterias principales (ej. Miguel Alemán).
- Costo real: pérdida de calidad de vida para trabajadores y riesgo a la competitividad industrial de Nuevo León como destino de inversión extranjera.

3. Objetivos y Alcance Geográfico

3.1 Alcance

La Zona Metropolitana de Monterrey (ZMM), con foco en 8 municipios industriales: Apodaca, Guadalupe, Santa Catarina, General Escobedo, San Nicolás de los Garza, García, Pesquería y Juárez. El análisis se centra en las vialidades de acceso a los parques industriales de mayor concentración de empleo manufacturero.

3.2 Horizonte temporal

Datos históricos: enero 2023 – marzo 2026 (granularidad horaria). Proyección: 3 años hacia adelante.

3.3 Objetivos específicos

- Cuantificar los tiempos reales de traslado hacia los parques industriales bajo distintas condiciones (hora, clima, eventos, accidentes).
- Clasificar qué vialidades entrarán en estado de Colapso Crítico en un horizonte de 3 años.
- Construir un modelo que prediga el nivel de congestión (bajo/medio/alto) usando variables contextuales — Opción D confirmada.
- Identificar perfiles de accesibilidad mediante clustering (zonas fluidas vs. zonas de encierro).

4. Metodología — Tres Modelos de ML

Modelo	Tipo	Variable objetivo	Descripción
Clustering de accesibilidad	No supervisado	—	Agrupar parques y zonas por Perfil de Accesibilidad: zonas fluidas vs. zonas de encierro.
Clasificación de congestión	Supervisado	nivel_congestión (bajo/medio/alto)	Predice nivel de congestión vial — Opción D. Reemplaza la regresión de tiempo de llegada.
Regresión de tiempo de llegada	Supervisado	Tiempo_Traslado (minutos)	Pendiente — requiere TARGET externo. Contingencia: Opción D ya confirmada.

5. Arquitectura de Datos — La “Super Tabla”

5.1 Concepto central

El dataset principal es una tabla horaria: cada fila representa una hora exacta del período 2023–2026 (35,064 filas). La granularidad horaria es deliberada: agrupar por día promedia el colapso de las 8:00 AM con la calma de las 3:00 AM, destruyendo la señal del modelo.

5.2 Estado de los pilares — ACTUALIZADO v3

Pilar	Columnas principales	Estado	Fuente
1 — Tiempo / Esqueleto	año, mes, dia_semana, hora_del_dia, es_fin_de_semana, intensidad_hora_pico (0/1/2), tipo_dia	Completado ✓	Generado (date_range 2023-2026)
2 — Eventos Masivos	asistencia_estimada, nivel_impacto (1-4), impacto_evento_activo (rolling -3h)	Completado ✓	CSV curado: eventos_masivos_zmm.csv (148 eventos)
3 — Clima	temperatura_c, nivel_lluvia (0–4)	Completado ✓	API Open-Meteo — Aeropuerto MTY (lat 25.7785, lon -100.1070)
4 — Siniestros	siniestros_zona_industrial, sin_apodaca/guadalupe/escobedo/garcia/juarez/pesqueria/santa_catarina/san_nicolas, Total de lesionados, Total de fallecidos, tiene_coordenadas, nivel_lluvia, temperatura_c	Completado ✓	OCISEVI — RATIV 2023, 2024, 2025
5 — Espacial	dist_industrial_promedio, dist_industrial_minima, siniestros_en_zona, masa_laboral_max	Completado ✓	DENUE + DBSCAN eps=0.003 + Haversine
TARGET	nivel_congestión (bajo/medio/alto)	Opción D confirmada	tiempo_traslado_min no fue obtenido — pivot a clasificación multiclase

6. Features del Dataset Final — ACTUALIZADO v3

Columna	Tipo	Descripción
fecha_hora	datetime	Índice temporal. Una fila = una hora exacta.
año / mes / dia_semana / hora_del_dia	int	Descomposición temporal básica.

es_fin_de_semana	bool (0/1)	1 si sábado o domingo.
intensidad_hora_pico	ordinal (0/1/2)	0=normal, 1=pico moderado (bordes), 2=pico intenso (8h, 14-15h, 18-19h).
tipo_dia	categorico	laboral_industrial (Lun-Vie), laboral_mixto (Sáb), fin_de_semana (Dom).
asistencia_estimada	int	Aforo del recinto del evento masivo esa hora (0 si sin evento).
nivel_impacto	int (0-4)	0=sin evento, 1= $\leq 22k$, 2= $\leq 42k$, 3= $\leq 53,500$, 4= $> 53,500$ (Fundidora).
impacto_evento_activo	float (0-4)	Rolling max 4h con shift -3h. Activa la alarma 3h antes del evento.
temperatura_c	float	Temperatura en °C. Fuente: Open-Meteo, Aeropuerto MTY.
nivel_lluvia	int (0-4)	0=seco, 1=brisa (0.1-5mm), 2=moderada (5-20mm), 3=fuerte (20-50mm), 4=torrencial (>50mm).
sinistros_zona_industrial	int	Sinistros por hora en 8 municipios industriales.
sin_apodaca / sin_guadalupe / sin_escobedo / sin_garcia / sin_juarez / sin_pesqueria / sin_santa_catarina / sin_san_nicolas	int	Conteo de sinistros por municipio industrial por hora. 8 columnas.
Total de lesionados / Total de fallecidos	int	Gravedad agregada por hora.
tiene_coordenadas	int	Cuántos sinistros de esa hora tienen coordenadas exactas.
dist_industrial_promedio	int	Distancia promedio sinistros→zona industrial más cercana (metros). NaN si sin coords.
dist_industrial_minima	int	Sinistro más cercano a zona industrial esa hora (metros). NaN si sin coords.
sinistros_en_zona	int	Sinistros dentro de 2km de zona industrial esa hora.
masa_laboral_max	int	Proxy de flujo laboral de la zona más activa esa hora (índice DENUÉ).
[TARGET] nivel_congestión	categorico (bajo/medio/alto)	Opción D — clasificación multiclase de congestión. Reemplaza tiempo_traslado_min.

7. Fuentes de Datos

Fuente	Tipo	Uso en proyecto
--------	------	-----------------

INEGI — DENUÉ	Censo de unidades económicas	Ubicación de empresas manufactureras con >30 empleados. Filtro ZMM por clave. Base del EDA inicial y del catálogo de zonas industriales.
INEGI — Censo Poblacional	Datos demográficos	Densidad poblacional por AGEB para proyección de crecimiento habitacional.
Open-Meteo API (archive)	Meteorología horaria	Temperatura y precipitación 2023–2026. Punto: Aeropuerto MTY (lat 25.7785, lon -100.1070). Libre y sin costo.
CSV eventos_masivos_zmm.csv	Eventos curado (148 registros)	Partidos Tigres/Rayados, festivales (Pa'l Norte, Live Out, Machaca Fest), conciertos. Incluye asistencia_estimada y nivel_impacto (1-4).
OCISEVI — RATIV	Siniestros viales	Registros históricos 2023-2025. 203,890 siniestros totales. Coordenadas: 2024 (100%), 2023 (21%), 2025 (56%).
CSV parques_industriales_maestro_v3.csv	Parques curados por Adrián	55 parques industriales con coordenadas verificadas. Usado para nombrar clusters DBSCAN en NB06.
Google Maps / Waze API	Tiempos de traslado reales	Variable TARGET original. No fue obtenida. Sustituida por Opción D (clasificación multiclase).
OpenData Nuevo León	Red vial y accidentes	Complemento de OCISEVI. Registros de accidentes y estructura de red vial.

8. Estado Actual del Pipeline — ACTUALIZADO v3

Notebook	Estado	Descripción	Output en data_processed
01_EDA_DENUE.ipynb	Completado ✓	Carga DENUÉ, filtra ZMM, define códigos SCIAN manufactureras + transporte, conserva lat/lon, filtra empresas >30 empleados, visualización folium.	denue_industrial_zmm_limpio.csv
02_FE_Tiempo.ipynb	Completado ✓ (revisado mar 2026)	Esqueleto horario 2023-2026 (35,064 filas). intensidad_hora_pico ordinal. tipo_dia. Merge con 148 eventos masivos. Rolling window -3h para impacto_evento_activo.	esqueleto_tiempo_eventos.csv
03_FE_Clima.ipynb	Completado ✓ (revisado mar 2026)	Descarga clima horario de Open-Meteo (Aeropuerto MTY). Merge con esqueleto. nivel_lluvia 0-4 basado en comportamiento vial regio. Verifica idempotencia.	esqueleto_tiempo_eventos_clima.csv
04_EDA_OCISEVI.ipynb	Completado ✓	EDA completo de 203,890 siniestros RATIV 2023-2025. Diagnóstico de calidad, encoding, coordenadas. Hallazgo: 3 picos horarios (8h,	rativ_unificado.csv (203,890 × 17)

		14-15h, 18-19h). Viernes = mayor siniestralidad.	
05_FE_OCISEVI.ipynb	Completado ✓	Parseo hora HH:MM con fallback. Flag tiene_coordenadas. Clima imputado con Open-Meteo. 8 municipios industriales incl. San Nicolás. GroupBy por hora. Left join + fillna(0).	super_tabla_completa.csv (35,064 × 25)
06_FE_Industria.ipynb	Completado ✓	DBSCAN eps=0.003 sobre DENUE: 131 clusters. Catálogo 183 zonas (Tipo A/B/C). Merge CSV Adrián: 36 clusters nombrados. Haversine 115,845 siniestros: 44.7% dentro de 2km. Índice masa laboral. Super tabla a 29 columnas.	catalogo_zonas_industriales.csv, super_tabla_completa.csv (35,064 × 29), nb06_heatmap_final.html
07_Modelos_ML.ipynb	SIGUIENTE PASO	3 modelos: KMeans (perfiles accesibilidad), Clasificación multiclase congestión (Opción D TARGET), Regresión (pendiente TARGET).	(pendiente)

9. Municipios Industriales — Lista Definitiva

Todos SCIAN 31-33/48-49 con >30 empleados. San Nicolás confirmado en NB06 (204 empresas, 28,631 siniestros — 2do municipio más activo en OCISEVI). Ciénega de Flores y Salinas Victoria excluidas con justificación de datos.

Municipio	Código INEGI	Empresas DENUE
Apodaca	6	533
Guadalupe	19	280
Santa Catarina	49	244
General Escobedo	18	208
San Nicolás de los Garza	46	204 — agregado en NB06
García	21	80
Pesquería	41	45
Juárez	26	31

10. Hallazgos Clave del EDA OCISEVI

10.1 Cobertura de datos

- 2023: 73,107 siniestros — 78.6% sin coordenadas (código 99).
- 2024: 67,956 siniestros — 100% con coordenadas lat/lon.
- 2025: 62,827 siniestros — 56.4% con coordenadas lat/lon.
- 11.9% sin dato en Condición de clima (código 99) — distribuido uniformemente entre años.

10.2 Patrones temporales

- Tres picos horarios confirmados: 8h (entrada turno matutino), 14-15h (cruce de turnos — hallazgo nuevo), 18-19h (turno vespertino).
- Viernes = mayor siniestralidad. Sábado: pico desplazado a 13-15h por medio turno industrial.
- El timestamp es la hora de reporte del oficial, no la hora exacta del accidente. Sesgo sistémico de ~15-45 min documentado.

10.3 Hallazgos NB06 — Zonas Industriales

- 44.7% de los siniestros georreferenciados ocurrieron dentro de 2km de una zona industrial.
- Top 3 focos: Corredor Industrial Santa Catarina Centro (2,141 siniestros), Ternium Planos Guerrero (1,583), Corredor Industrial SN-11 (1,504).
- 14,017 horas sin dato espacial (NaN) — siniestros sin coordenadas, principalmente 2023.

11. Rationale de Decisiones Técnicas Clave — ACTUALIZADO v3

Decisión	Qué se hizo	Por qué — razonamiento
Granularidad horaria	El esqueleto usa una fila por hora.	El tráfico es un fenómeno de alta frecuencia. Agrupar por día destruiría la señal del modelo.
Filtro >30 empleados (DENUE)	Se descartaron empresas pequeñas.	Tortillerías y talleres dominaban el conteo pero generan tráfico despreciable.
intensidad_hora_pico ordinal (0/1/2)	Reemplaza la variable binaria es_hora_pico.	El EDA reveló gradiente real: 8h y 14-15h concentran más accidentes que horas adyacentes.
tipo_dia: 3 categorías	laboral_industrial / laboral_mixto / fin_de_semana.	El heatmap hora×día reveló tres perfiles distintos de movilidad.
nivel_impacto 4 niveles por aforo	Redefinición desde 3 niveles subjetivos.	Los niveles originales eran inconsistentes. Los 4 niveles basados en aforo son coherentes.
Aeropuerto MTY como referencia climática	lat 25.7785, lon -100.1070.	Punto oficial SMN más cercano a Apodaca (9 km) y Pesquería (6 km).
nivel_lluvia 5 niveles	precipitacion_mm discretizada con pd.cut.	La brisnita (0.1-5mm) es el nivel más peligroso, no el torrencial.

Rolling window -3h para eventos	impacto_evento_activo = rolling max 4h con shift(-3).	El tráfico se acumula antes del evento, no en el momento exacto.
8 municipios industriales	Se agregó San Nicolás (código INEGI 46).	204 empresas DENU SCIAN 31-33/48-49, 28,631 siniestros OCISEVI — 2do municipio más activo.
NaN → 0 en siniestros	fillna(0) tras left join.	Horas sin accidentes son información real, no datos faltantes.
Conteo por municipio (no flag binario)	Columnas sin_municipio con conteo real.	Un flag 0/1 destruye la señal — no distingue 1 accidente de 10 en Apodaca.
DBSCAN eps=0.003 (~330m)	Tuneado con gráfica k-distancias.	eps=0.005 fusionaba parques distintos, eps=0.002 perdía 48% de establecimientos.
Catálogo 3 tipos de zona	A=zona densa (≥5 empresas), B=ancla manufactura (SCIAN 31-33, 251+), C=ancla transporte (SCIAN 48-49, 251+).	DBSCAN solo no captura empresas ancla aisladas (KIA, Caterpillar, Ternium).
Radio fijo 2km Haversine	Buffer de proximidad para siniestros.	Metodológicamente defendible, consistente con literatura de proximidad industrial.
Masa laboral como índice ordinal	Suma de valores medios de rangos DENU por zona.	Proxy de flujo laboral — señal de intensidad, no conteo real de empleados.
Ternium Churubusco excluida	Registrada en Monterrey por DENU.	Municipio fuera del alcance geográfico del modelo.
Delicias del Contry eliminada	No tiene planta verificable.	Pasó filtro SCIAN 311 pero no genera tráfico industrial real.
14,017 nulos en features espaciales	Horas sin siniestros georreferenciados quedan como NaN.	Ausencia real de dato — principalmente 2023 (21% cobertura coords). No se imputa con cero.
Opción D confirmada como TARGET	Nivel de congestión bajo/medio/alto.	tiempo_traslado_min no fue obtenido — clasificación multiclase preserva todo el FE.

12. Riesgos, Incertidumbres y Contingencias

12.1 Riesgo crítico — Variable TARGET

RIESGO RESUELTO: tiempo_traslado_min no fue obtenido. Se confirmó Opción D: pivot a clasificación multiclase de congestión (bajo/medio/alto). Preserva todo el trabajo de Feature Engineering.

Riesgo	Probabilidad	Impacto	Mitigación
--------	--------------	---------	------------

Variable TARGET no disponible	RESUELTO	Alto	Opción D confirmada: clasificación multiclase de congestión.
Fecha de entrega 10/abril insuficiente	Media	Alto	Priorizar 3 modelos simples. Profundidad > cantidad de features.
Siniestros sin coordenadas (2023)	Ocurrido	Medio	14,017 horas con NaN en features espaciales. Modelo maneja con imputation.
Google Colab desconecta sesiones largas	Alta	Bajo	Guardar en Drive al final de cada celda. Ya implementado.

13. Principios de Trabajo y Buenas Prácticas

- Honestidad técnica: prioridad al diagnóstico correcto sobre validación. No hacer por hacer.
- Commits descriptivos en GitHub con cada avance relevante.
- Feature engineering guiado por el libro “Feature Engineering for Machine Learning” (O’Reilly) como referencia metodológica.
- Idempotencia en notebooks: cada celda verifica si el proceso ya fue aplicado antes de re-ejecutar.
- Separación clara entre data_raw (sin tocar) y data_processed (transformado y documentado).
- Granularidad horaria justificada metodológicamente, no arbitraria.
- Visualización como herramienta de validación — no solo de presentación.
- Entender antes de implementar: cada decisión técnica debe comprenderse, no copiarse.

14. Perfil del Autor y Filosofía del Proyecto

14.1 Contexto personal

Cristopher, 26 años, Monterrey (Apodaca, NL). Estudiante de 5.º semestre de Ingeniería en Tecnología de Software en FIME (UANL). Se especializó en IA desde 2023 principalmente como usuario avanzado de LLMs. Este proyecto representa su primera experiencia construyendo con IA — no solo usándola. El curso Samsung Innovation Campus + UDEM es el marco académico, pero el proyecto es auténticamente propio.

14.2 Mentalidad y forma de trabajar

- Honestidad por encima de confort: prefiere diagnóstico directo aunque sea incómodo.
- Aprender haciendo: cada decisión técnica debe entenderse, no copiarse.
- Orientación a la calidad: GitHub, estructura de carpetas, commits descriptivos — desde el inicio porque así se debe hacer.
- Adaptabilidad deliberada: si el enfoque necesita cambiar para mejorar el resultado, el cambio es bienvenido.
- Propósito social como norte: el proyecto busca aportar valor real a la ZMM y a la calidad de vida de trabajadores industriales.

14.3 Guía para colaborar con este proyecto

- No asumir que las decisiones son inamovibles — siempre es válido preguntar si una decisión sigue siendo la mejor.
- Priorizar que Christopher entienda lo que se está haciendo, no solo que funcione. La explicación es parte del entregable.
- Si hay dos formas de resolver algo, mencionar las dos con sus trade-offs reales.
- El libro de O'Reilly es la referencia metodológica. Si hay conflicto con una sugerencia, justificar la diferencia.
- El 10 de abril es una fecha real, no negociable.

Este documento fue actualizado en abril 2026 tras completar NB05 y NB06. Versión: v3. Cualquier LLM o colaborador que procese este documento puede asumir este estado como punto de partida preciso del trabajo.